

Recuperação de contexto para IA generativa em materiais educacionais abertos

Corretude, eficiência e qualidade de três estratégias de ordenação e busca sobre o livro *Pense Python*

João Cosme Sena Sá · Eduardo Henrique do Lago Silva · Helena Carvalho Leal
Hernandison da Silva Bispo · Nadianne Maria dos Santos Galvão · Rafael Takeguma Goto

Tema 8 · Projeto e Análise de Algoritmos · Prof. Glauco Carneiro · PROCC/UFS · 24/09/2026

Problema e corpus

- **Entrada:** corpus C com N chunks, consulta q em português, k resultados
- **Saída:** lista R com até k chunks, ordenada por relevância não crescente, sem repetição
- **Relevância** tf-idf lexical: $tf = 1 + \ln f$, $idf = \ln((N+1)/(df+1)) + 1$
- **Ordem total:** maior escore primeiro; empate decidido pela posição no livro (source_order)
- **Casos de borda:** consulta vazia, k = 0 ou nenhum termo casando devolvem lista vazia; k maior que os candidatos devolve todos

Pense Python

- Tradução livre da 3ª ed. de *Think Python* (Downey; trad. Carlson)
- 21 notebooks, 817.578 bytes, commit fixado e hash conferido
- 2.737 chunks (256 tokens, sobreposição 32, corte por célula)
- 30 consultas escritas antes dos resultados: 10 fáceis, 10 médias, 10 difíceis
- Texto CC BY-NC-SA: não versionado, baixado por script

Quatro configurações, uma só função de relevância

Config.	Busca	Ordenação	Papel
C1	varredura linear	Insertion Sort (equipe)	baseline
C2	índice invertido + busca binária no vocabulário	Merge Sort (equipe)	busca indexada
C3	varredura linear	Merge Sort (equipe)	divisão e conquista
C4	TfidfVectorizer + cosseno (scikit-learn)	biblioteca	referência externa

C1, C2 e C3 devem devolver exatamente a mesma lista: só o custo muda. C4 normaliza os vetores (norma L2) e por isso pode devolver outra lista; é analisada à parte e não substitui nenhuma exigência.

Cinco algoritmos obrigatórios cobertos: busca linear · Insertion Sort · Merge Sort (também a divisão e conquista) · busca binária · comparação com biblioteca

C2: índice invertido com busca binária

1

Construção

cada termo do corpus ganha a lista crescente das posições dos chunks em que aparece; o vocabulário é ordenado uma vez

2

Busca binária

cada termo da consulta é localizado no vocabulário em $\Theta(\log V)$ comparações

3

União

as listas dos termos encontrados são unidas com dois ponteiros, como no merge

4

Pontuação e Merge Sort

só os candidatos da união são pontuados, com a mesma função de C1 e C3, e ordenados

Corretude da busca binária

Só vale porque o vocabulário está ordenado pela mesma chave que o laço compara.
Invariante: se o termo existe, está em `vocab[lo..hi]` no início de cada iteração.

Custo real da consulta

$O(m \log V + m \cdot S + P(m + n))$

S = soma dos postings dos termos, P = candidatos, n = tokens do chunk

Corretude do Merge Sort

Teorema. Para uma lista finita de candidatos com `source_order` únicos e a ordem total $\leq$ (maior escore; empate por menor `source_order`), `merge_sort` termina e devolve uma permutação da entrada ordenada por $\leq$.

Invariante de `_merge`

- A saída está ordenada por $\leq$
- Contém exatamente os elementos já consumidos de *left* e *right*
- Todo elemento da saída $\leq$ qualquer elemento ainda não consumido
- Inicialização, manutenção e término verificados

Indução no tamanho

- Base: $|A| \leq 1$ devolve a própria lista
- Passo: as metades, menores que n , são corretas por hipótese; o merge junta preservando a ordem
- A recursão termina: $\lfloor n/2 \rfloor < n$

Limites do argumento

- Garante a ordenação, não a relevância semântica
- Exige escores finitos e ids únicos
- Testes: entradas embaralhadas, empates, k maior que os candidatos; 131 testes passando

Modelo RAM, casos e recorrências

Algoritmo	Melhor	Pior	Médio	Espaço extra
Pontuação linear (N chunks, m termos, L tokens)	$\Theta(N \cdot m + L)$	$\Theta(N \cdot m + L)$	$\Theta(N \cdot m + L)$	$\Theta(P)$
Insertion Sort (P candidatos)	$\Theta(P)$	$\Theta(P^2)$	$\Theta(P^2)$	$\Theta(1)$
Merge Sort (P candidatos)	$\Theta(P \log P)$	$\Theta(P \log P)$	$\Theta(P \log P)$	$\Theta(P)$
Busca binária (V termos)	$\Theta(1)$	$\Theta(\log V)$	$\Theta(\log V)$	$\Theta(1)$

Merge Sort: $T(P) = 2 \cdot T(P/2) + \Theta(P) \Rightarrow \Theta(P \log P)$
duas chamadas nas metades; o merge percorre as duas uma vez

Busca binária: $T(V) = T(V/2) + \Theta(1) \Rightarrow \Theta(\log V)$
uma chamada sobre metade do vocabulário; $\Theta(1)$ no meio e na comparação

Parâmetros declarados: N chunks, L tokens do corpus, m termos da consulta, V termos distintos, P candidatos com $\text{score} > 0$, k resultados.

A pontuação recalcula os termos de cada chunk a cada consulta, por isso o termo L entra no custo: no corpus inteiro, $L = 72.205$ supera $N \cdot m = 27.370$.

Metodologia experimental

3.600

execuções registradas, uma
linha por execução

$4 \times 3 \times 30$

configurações $\times$ tamanhos de
corpus $\times$ consultas

$k = 5$ e 10


5 repetições após 2
aquecimentos descartados

0

divergências entre C1, C2 e
C3 em 180 combinações

- Tamanhos: 25 %, 50 % e 100 % dos chunks (684, 1.368 e 2.737), sorteados por capítulo com semente 2026
- Ordem das configurações sorteada em cada bloco; mediana e intervalo interquartil por célula
- Métricas: tempo de ingestão, índice, busca, ordenação, consulta e total; memória de pico (tracemalloc); comparações e trocas por contadores internos; Precision@k, Recall@k, nDCG@k e MRR contra o gabarito
- Ambiente registrado: Apple M5, macOS, Python 3.14.7, scikit-learn 1.6.1, commit e linha de comando
- Reprodução: `python scripts/reproduzir_tudo.py`, conferida em máquina limpa com resultados idênticos

Comparações: quadrático contra $n \log n$



$\times 4$ vs $\times 2,2$

comparações por dobra de candidatos: Insertion (C1)
e Merge (C2, C3)


$36\times$

menos comparações no corpus inteiro para devolver
a mesma lista

Insertion Sort fez 93 % de $P^2/4$; Merge Sort, 85 % de $P \log_2 P$ (medianas por consulta). A C2 soma poucas dezenas de comparações da busca binária.

Tempo, memória e escalabilidade

Configuração (corpus inteiro)	Total (ms)	Consulta (ms)	Comparações	Memória
C1 varredura + Insertion	167,0	127,9	461.702	451 KiB
C2 índice + binária + Merge	128,6	47,7	13.039	1.659 KiB
C3 varredura + Merge	105,7	65,8	12.746	452 KiB
C4 scikit-learn	87,1	0,4	n/a	2.581 KiB



- C1 cresce 2,4× por dobra do corpus: a ordenação sobe de 13 % para 38 % do total
- C2 tem a consulta mais rápida da equipe (47,7 ms), mas paga 40,8 ms de índice; compensa a partir da 3ª consulta com o índice reaproveitado
- Preço da C2: 3,7× a memória da C3

Qualidade da recuperação

Configuração	P@5	P@10	R@10	nDCG@10	MRR
C1 = C2 = C3	0,087	0,077	0,158	0,141	0,248
C4 scikit-learn	0,247	0,183	0,387	0,366	0,551

14/30

consultas sem trecho
relevante no top-10
(equipe)

2/30

idem, na referência C4

- Referência: gabarito de 146 pares consulta–chunk, com justificativa, escolhidos antes de ver qualquer ranking
- C1, C2 e C3 têm a mesma qualidade porque devolvem a mesma lista: o algoritmo define o custo, não a qualidade
- A C4 acerta quase 3× mais: a norma L2 impede que trechos longos, como o Glossário (37 % do top-10 da equipe), dominem
- Nas consultas difíceis as duas empatam em nível baixo (0,10 vs 0,12): limite da busca lexical quando a pergunta usa palavras diferentes do livro

Relação com IA generativa e RAG

Prompt

os k chunks entram como bloco de contexto, cada um com a origem (notebook, seção) para citação

k e tamanho do chunk

mais trechos e trechos maiores custam tokens e latência; a ordem importa (*lost in the middle*)

Lexical vs. semântico

tf-idf casa palavras, não sinônimos: "laço" não acha "loop"; embeddings achariam

Riscos

recuperação incompleta ou irrelevante em 14 das 30 consultas leva o LLM a responder sem base; contexto desatualizado é controlado pelo commit fixado

Rastreabilidade

cada chunk carrega a proveniência: a resposta pode citar a fonte exata e o usuário confere

Trade-offs

C4: 3× a precisão e consulta rápida, com 6× a memória da C3; C2: consulta rápida, com índice de 3,7× a memória

Limitações, ameaças à validade e uso de IA

Ameaças à validade

- A hipótese de esparsidade não se confirmou: palavras como "que" e "de" fazem 51 % dos chunks virar candidato, e o índice ganhou só 1,4× na consulta
- Três tamanhos mostram tendência, não provam ordem assintótica; o cronômetro mede o interpretador tanto quanto o algoritmo
- Os chunks seguem as células dos notebooks (mediana de 13 tokens), não janelas de 256
- Um livro introdutório é estudo de caso; julgamento de relevância binário e com uma avaliadora

Uso crítico de IA generativa

- Registro por uso em docs/USO_DE_IA.md: ferramenta, finalidade, prompts, sugestões aceitas e rejeitadas
- Erros detectados: numeração de C2/C3 trocada; análise da C2 sem o termo da pontuação dos candidatos; empate tratado como simples estabilidade
- Nada entrou sem verificação: 131 testes, gabarito calculado à parte, contadores confrontados com $P^2/4$ e $P \log P$, teste de mutação do Merge Sort

O que aprendemos

O algoritmo define o custo

C1, C2 e C3 devolvem a mesma lista com 36× de diferença nas comparações

A função de relevância define a qualidade

a normalização L2 da C4 triplica a precisão sem mudar o algoritmo

A hipótese precisa ser testada

o índice só compensa quando os termos são raros, e no português corrente não são

github.com/joaocss/PAA_UFS_2026_2_SenaSa_Joao_Bispo_Hernandison_Galvao_Nadianne_Goto_Rafael_Leal_Helena_Silva_Eduardo

Reprodução completa: `python scripts/reproduzir_tudo.py`